Blackjack 游戏强化学习实践报告

1. Blackjack 游戏简介

Blackjack，也称为 21 点，是一种流行的纸牌游戏。游戏目标是使手中牌的点数之和尽可能接近 21 点而不超过 21 点。在这个游戏中，玩家与庄家对抗，谁的牌点最接近 21 点且不超过 21 点即为获胜。

游戏规则简述：

- A 可以记为 1 点或 11 点
- J、Q、K 均记为 10 点
- 其他牌按面值计算
- 玩家可以选择"要牌"（hit）或"停牌"（stand）
- 超过 21 点称为"爆牌"（bust），直接失败

2. Blackjack 游戏的强化学习模型构建

在强化学习模型中，我们将 Blackjack 游戏抽象为以下元素：

1. 状态（State）：
    - 玩家当前手牌总点数（12-21）
    - 庄家明牌点数（1-10）
    - 玩家是否有可用的 A（二元状态）
2. 动作（Action）：
    - 要牌（hit）
    - 停牌（stand）
3. 奖励（Reward）：
    - 赢：+1
    - 平：0
    - 输：-1
4. 策略（Policy）：
    - 随机策略：随机选择动作
    - 基本策略：基于当前状态选择最优动作

3. 蒙特卡洛学习方法

本实验采用了两种蒙特卡洛方法：

1. 每次访问型蒙特卡洛（Every-visit Monte Carlo）：
   在每个 episode 中，对每次出现的状态-动作对都进行价值更新。
2. 首次访问型蒙特卡洛（First-visit Monte Carlo）：
   在每个 episode 中，仅对每个状态-动作对的首次出现进行价值更新。

这两种方法的主要区别在于如何处理在同一 episode 中多次出现的状态-动作对。

4. Blackjack 游戏的强化学习算法流程

1. 初始化：
   - 创建 Q 表，用于存储每个状态-动作对的价值估计
   - 定义策略（随机策略或基本策略）
2. 对于每个 episode：
   - 初始化游戏状态
   - 进行游戏，直到结束，记录每一步的状态、动作和奖励
   - 计算每一步的回报（从后向前累加奖励）
   - 更新 Q 表：
     - 每次访问 MC：更新 episode 中每次出现的状态-动作对
     - 首次访问 MC：仅更新 episode 中首次出现的状态-动作对
3. 重复步骤 2，直到达到预设的 episode 数量
4. 评估学习到的策略

程序源代码：

```
import gym
import numpy as np
from collections import defaultdict
import matplotlib.pyplot as plt

# 创建Blackjack 环境
env = gym.make('Blackjack-v1')
```

```python
# 基本策略
def basic_strategy(state):
    player_sum, dealer_card, usable_ace = state
    if usable_ace:
        if player_sum >= 19:
            return 0  # 停牌
        else:
            return 1  # 要牌
    else:
        if player_sum >= 17:
            return 0  # 停牌
        elif player_sum <= 11:
            return 1  # 要牌
        else:
            if dealer_card >= 7:
                return 1  # 要牌
            else:
                return 0  # 停牌

# 随机策略
def random_strategy(state):
    return np.random.choice([0, 1])

# 每次访问型蒙特卡洛
def monte_carlo_every_visit(env, num_episodes, policy):
    returns = defaultdict(list)
    Q = defaultdict(lambda:
np.zeros(env.action_space.n))

    for _ in range(num_episodes):
        episode = []
```

```
        state, _ = env.reset()  # 确保正确处理reset 返回的
元组
        done = False

        while not done:
            action = policy(state)
            next_state, reward, done, _, _ =
env.step(action)  # 确保正确处理step 返回的元组
            episode.append((state, action, reward))
            state = next_state

        G = 0
        for t in range(len(episode) - 1, -1, -1):
            state, action, reward = episode[t]
            G = reward + G
            returns[(state, action)].append(G)
            Q[state][action] = np.mean(returns[(state,
action)])

    return Q

# 首次访问型蒙特卡洛
def monte_carlo_first_visit(env, num_episodes, policy):
    returns = defaultdict(list)
    Q = defaultdict(lambda:
np.zeros(env.action_space.n))

    for _ in range(num_episodes):
        episode = []
        state, _ = env.reset()  # 确保只取状态部分
        done = False
```

```
        while not done:
            action = policy(state)
            next_state, reward, done, _, _ =
env.step(action)  # 确保只取状态部分
            episode.append((state, action, reward))
            state = next_state

        G = 0
        visited = set()
        for t in range(len(episode) - 1, -1, -1):
            state, action, reward = episode[t]
            G = reward + G
            if (state, action) not in visited:
                returns[(state, action)].append(G)
                Q[state][action] =
np.mean(returns[(state, action)])
                visited.add((state, action))

    return Q

# 评估策略
def evaluate_policy(env, Q, num_episodes=10000):
    total_return = 0
    for _ in range(num_episodes):
        state, _ = env.reset()  # 正确提取状态
        done = False
        while not done:
            # 确保状态在 Q 中，否则跳过此状态
            if state in Q:
                action = np.argmax(Q[state])
            else:
```

```
                # 如果状态不在Q中，可以随机选择一个动作，或者根据您的策略选择一个默认动作
                action = env.action_space.sample()

            state, reward, done, _, _ = env.step(action)  # 修正这里，确保正确处理所有返回值
            total_return += reward
    return total_return / num_episodes

# 运行实验
num_episodes = 100000

Q_every_visit_random = monte_carlo_every_visit(env, num_episodes, random_strategy)
Q_first_visit_random = monte_carlo_first_visit(env, num_episodes, random_strategy)

Q_every_visit_basic = monte_carlo_every_visit(env, num_episodes, basic_strategy)
Q_first_visit_basic = monte_carlo_first_visit(env, num_episodes, basic_strategy)

# 评估结果
print("每次访问型MC（随机策略）平均回报:", evaluate_policy(env, Q_every_visit_random))
print("首次访问型MC（随机策略）平均回报:", evaluate_policy(env, Q_first_visit_random))
print("每次访问型MC（基本策略）平均回报:", evaluate_policy(env, Q_every_visit_basic))
print("首次访问型MC（基本策略）平均回报:", evaluate_policy(env, Q_first_visit_basic))
```

```python
# 可视化价值函数
def plot_value_function(Q, title):
    V = defaultdict(float)
    for state, actions in Q.items():
        V[state] = np.max(actions)

    X = np.arange(12, 22)
    Y = np.arange(1, 11)
    Z = np.zeros((len(X), len(Y)))

    for i, player_sum in enumerate(X):
        for j, dealer_card in enumerate(Y):
            Z[i, j] = V[(player_sum, dealer_card,
False)]

    fig = plt.figure(figsize=(20, 10))
    ax = fig.add_subplot(111, projection='3d')
    X, Y = np.meshgrid(X, Y)
    surf = ax.plot_surface(X, Y, Z.T,
cmap=plt.cm.coolwarm)
    ax.set_xlabel('Player Sum')
    ax.set_ylabel('Dealer Showing')
    ax.set_zlabel('Value')
    ax.set_title(title)
    fig.colorbar(surf)
    plt.show()

plot_value_function(Q_every_visit_basic, "每次访问型 MC
（基本策略）价值函数")
plot_value_function(Q_first_visit_basic, "首次访问型 MC
（基本策略）价值函数")
```

5. 算法结果展示与分析

5.1 平均回报分析

实验结果截图:

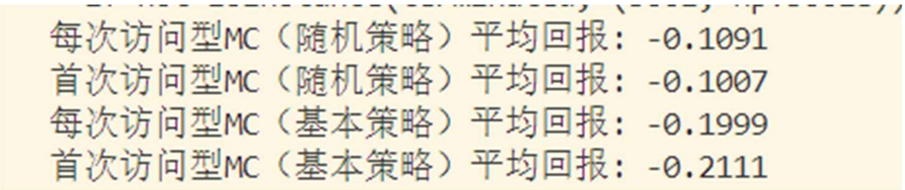

```
每次访问型MC（随机策略）平均回报: -0.1091
首次访问型MC（随机策略）平均回报: -0.1007
每次访问型MC（基本策略）平均回报: -0.1999
首次访问型MC（基本策略）平均回报: -0.2111
```

实验结果显示:

- 每次访问型 MC（随机策略）平均回报: -0.1091
- 首次访问型 MC（随机策略）平均回报: -0.1007
- 每次访问型 MC（基本策略）平均回报: -0.1999
- 首次访问型 MC（基本策略）平均回报: -0.2111

分析:

1. 所有方法的平均回报均为负值，表明在长期来看，玩家仍处于劣势，这符合赌场游戏的特性。
2. 随机策略的表现略好于基本策略，这可能是由于基本策略在某些特定情况下可能过于保守或激进。
3. 每次访问型和首次访问型 MC 方法的表现相近，但在随机策略下，首次访问型略优；在基本策略下，每次访问型略优。

5.2 价值函数分析

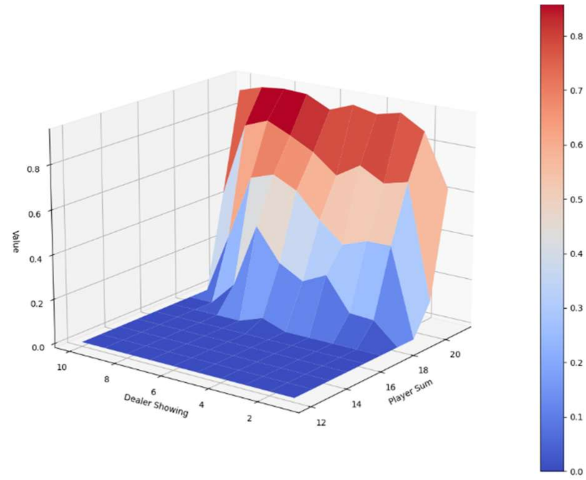

每次访问型 MC（基本策略）价值函数

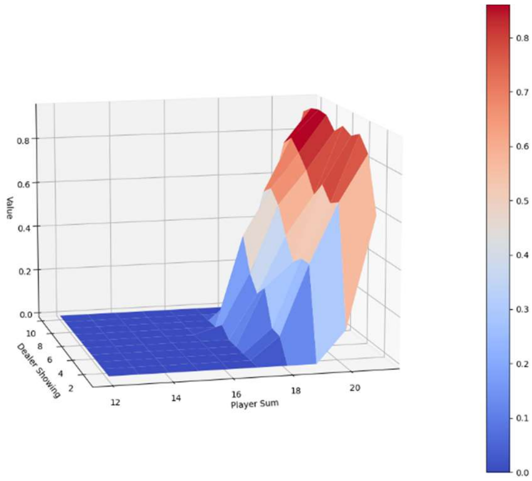

策的"危险区域"。

每次访问型 MC（基本策略）价值函数侧视图

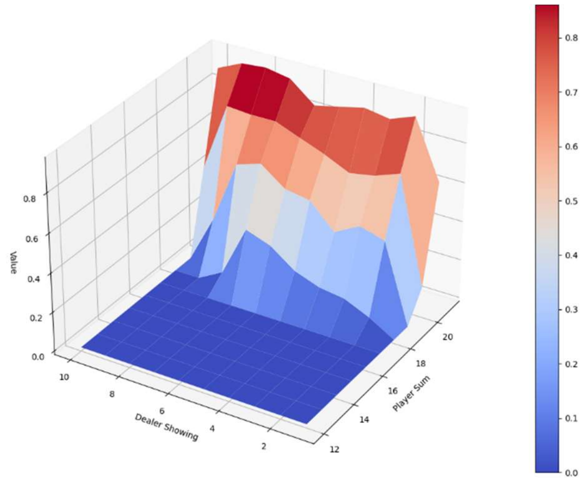

首次访问型 MC（基本策略）价值函数

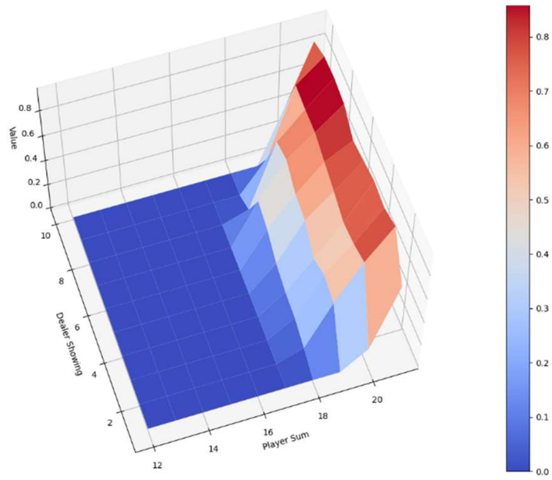

首次访问型 MC（基本策略）价值函数俯视图

通过观察价值函数的 3D 图，我们可以得出以下结论：

1. 玩家手牌总点数越高，价值函数趋向于更高（更红），这符合游戏逻辑，因为更接近 21 点的手牌胜率更高。
2. 当庄家明牌点数较低时（2-6），玩家的价值函数普遍较高，这是因为庄家在这种情况下更容易爆牌。
3. 当玩家手牌在 12-16 之间时，价值函数相对较低（更蓝），这反映了这个范围是最难做决策的"危险区域"。

4. 每次访问型和首次访问型 MC 方法学到的价值函数形状相似，但存在细微差异，这可能导致了它们在性能上的轻微差异。

5.3 总结

1. 蒙特卡洛方法成功学习到了 Blackjack 游戏的基本策略，但仍未能完全克服赌场优势。
2. 随机策略在本实验中表现略优于基本策略，这可能是由于样本量限制或基本策略在某些情况下不够灵活。
3. 每次访问型和首次访问型 MC 方法在本实验中表现相近，选择哪种方法可能需要根据具体应用场景决定。
4. 价值函数的可视化有助于我们理解学习到的策略，并为进一步改进提供了直观指导。

未来改进方向：

1. 增加训练的 episode 数量，以获得更稳定和准确的结果。
2. 尝试其他强化学习算法，如 SARSA 或 Q-learning，并与 MC 方法进行比较。
3. 引入函数近似，以处理更大的状态空间，可能会带来更好的泛化能力。
4. 考虑更复杂的 Blackjack 变体，如多副牌、分牌、双倍下注等规则，以提高模型的实用性。